

Sistemas Distribuídos

Comunicação em Sistemas Distribuídos camada inferior de *middleware*

Introdução

- Camada "inferior" do Middleware, relacionada com detalhes de
 - comunicação
 - representação externa de dados
 - marshalling
- Características de protocolos de comunicação entre processos num SD

Middleware: camada inferior



Remote invocation, indirect communication

This chapter

Underlying interprocess communication primitives: Sockets, message passing, multicast support, overlay networks Middleware layers

UDP and TCP

- recordar...
 - UDP
 - abstração para comunicação entre processos
 - permite o envio de mensagens isoladas, através de pacotes chamados datagramas
 - ◆ TCP
 - abstração para comunicação entre processos
 - fornece uma ligação (stream, canal) bidirecional entre dois processos
- Comunicação: Operações envolvidas uma mensagem:
 - send
 - receive

- Existe uma fila-de-espera (buffer) associada ao processo destinatário
 - envio: a mensagem é adicionada à fila remota
 - recepção: a mensagem é retirada da fila local
- Comunicação síncrona: os processos emissor e receptor sincronizam-se a cada mensagem
 - send e receive são operações bloqueantes
 - o emissor fica parado no send até que o receive seja efetuado
 - ao efetuar um receive, o receptor fica bloqueado até a mensagem chegar
- Comunicação assíncrona: não há sincronização
 - send não é bloqueante
 - o emissor prossegue assim que mensagem passa ao buffer local de saída
 - receive pode ser bloqueante ou n\(\tilde{a}\) o bloqueante*
 - * o processo prossegue com um buffer que será preenchido em background, havendo uma notificação quando isso acontecer

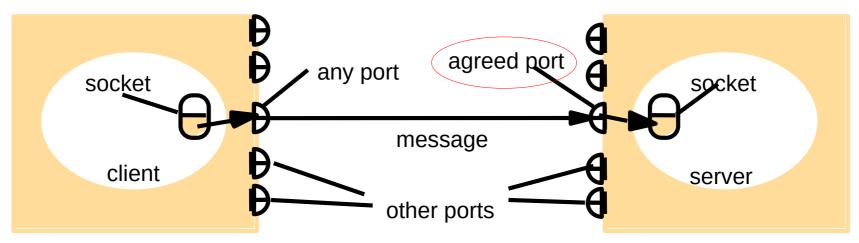
- Destino da mensagem: (endereço, porto)
- Porto:
 - inteiro, identifica o destinatário da mensagem numa máquina
 - associado a um só destinatário mas usado por vários emissores
 - um processo pode receber mensagens de vários portos
 - um processo não partilha portos com outros processos na mesma máquina
 - uma máquina tem 2¹⁶ números para portos disponíveis
- Preocupações com o envio de mensagens:
 - fiabilidade: garantia de entrega das mensagens, ainda que alguns pacotes sejam perdidos
 - ordenação correta: garantia de que as mensagens são entregues pela ordem com que foram enviadas (e não há trocas)

- O endereço do destinatário ou de um serviço:
 - endereço IP definido
 - obtido de um servidor de nomes (binder)
 - alguma transparência de localização
- UDP e TCP usam <u>Sockets</u>

(socket: abstração para o acesso ao canal de comunicação)

- Comunicação entre processos
 - transmitir mensagens entre o socket de um processo e o socket de outro processo
- Para um processo receber mensagens:
 - o socket tem de estar bound a um porto local e um endereço da máquina onde é executado

Sockets e Portos



Internet address = 138.37.94.248

Internet address = 138.37.88.249

UDP

- não há acknowledgement (confirmação) ou reenvios
- em caso de falha a mensagem não é recebida
- tamanho da mensagem:
 - IP: até 2^16 bytes (headers + mensagem) (muitos ambientes limitam 8K)
 - para mensagens maiores, as aplicações devem dividir a mensagem em vários pedaços (chunks)
- Para enviar ou receber
 - é necessário um socket associado (bound) a um porto local e endereço IP
- send n\u00e3o bloqueante; receive: bloqueante (com poss\u00e1vel timeout)
- Modo receive from any
 - a origem da mensagem é desconhecida
 - o endereço e porto do emissor é detectado na operação receive

UDP

- Modelo de Falhas
 - falhas de omissão: algumas mensagens podem eventualmente perderse (não chegam, ou têm erros de checksum ou falta de espaço no buffer de chegada)
 - ordenação: não há garantia de entrega pela ordem de envio
- Caberá às aplicações assegurar algumas garantias de fiabilidade, por exemplo através de confirmações (ack.)
- Utilização de UDP
 - por vezes o risco destas falhas pontuais pode ser tolerável/aceitável
 - vantagem: menos overheads relacionados
 - estado da informação na origem e destino
 - latência
 - exemplo de utilização: DNS

Cliente UDP

```
import java.net.*;
import java.io.*;
public class UDPClient{
  public static void main(String args[]){
           // args give message contents and server hostname
           DatagramSocket aSocket = null;
            try {
                      aSocket = new DatagramSocket();
                      byte []m = args[0].getBytes();
                      InetAddress aHost = InetAddress.getByName(args[1]);
                      int serverPort = 6789;
                      DatagramPacket request = new DatagramPacket(m, args[0].length(), aHost, serverPort);
                      aSocket.send(request);
                      byte[] buffer = new byte[1000];
                      DatagramPacket reply = new DatagramPacket(buffer, buffer.length);
                      aSocket.receive(reply);
                      System.out.println("Reply: " + new String(reply.getData()));
            }catch (SocketException e){System.out.println("Socket: " + e.getMessage());
            }catch (IOException e){System.out.println("IO: " + e.getMessage());}
           }finally {if(aSocket != null) aSocket.close();}
```

Servidor UDP em ciclo a atender clientes

```
import java.net.*;
import java.io.*;
public class UDPServer{
           public static void main(String args[]){
            DatagramSocket aSocket = null;
              try{
                       aSocket = new DatagramSocket(6789);
                       byte[] buffer = new byte[1000];
                       while(true){
                          DatagramPacket request = new DatagramPacket(buffer, buffer.length);
                         aSocket.receive(request);
                         DatagramPacket reply = new DatagramPacket(request.getData(),
                                   request.getLength(), request.getAddress(), request.getPort());
                         aSocket.send(reply);
              }catch (SocketException e){System.out.println("Socket: " + e.getMessage());
              }catch (IOException e) {System.out.println("IO: " + e.getMessage());}
            }finally {if(aSocket != null) aSocket.close();}
                          Instructor's Guide for Coulouris, Dollimore, Kindberg and Blair, Distributed Systems: Concepts and Design Edn. 5
```

TCP

- tamanho da mensagem: à responsabilidade da aplicação, tamanho arbitrário. O TCP envia (de modo transparente) os dados em blocos, desde o buffer de saída
- usa acknowledgement e checksums
 - garante a entrega desses blocos reenviando aqueles cuja confirmação não chega antes de um timeout
- controlo do fluxo de dados: se o emissor é mais rápido, então é bloqueado até que o receptor tenha consumido alguns dados
- elimina duplicados e garante a ordem correta na recepção (através de números de sequência em cada pacote IP)
- com conexão
- bloqueante para leitura; bloqueante no envio <u>apenas se</u> o controlo de fluxo atuar

TCP

Modelo de Falhas

- não é reliable/fiável, na medida em que não garante a entrega em todos os cenários (quando há dificuldades na rede, a ligação pode perder-se)
- um processo não distingue entre falha na rede e falha no processo do outro lado da ligação
- um processo não sabe se uma mensagem (recente) já foi ou não recebida (pode estar ainda a ser reenviada)
- Utilizações de TCP
 - HTTP, FTP, Telnet, SMTP

Cliente TCP: connect, send, receive

```
import java.net.*;
import java.io.*;
public class TCPClient {
            public static void main (String args[]) {
            // arguments supply message and hostname of destination
            Socket s = null:
              try{
                        int\ serverPort = 7896:
                        s = new Socket(args[1], serverPort);
                         DataInputStream in = new DataInputStream( s.getInputStream());
                         DataOutputStream out =
                                     new DataOutputStream( s.getOutputStream());
                        out.writeUTF(args[0]);
                                                             // UTF is a string encoding see Sn 4.3
                         String\ data = in.readUTF();
                        System.out.println("Received: "+ data);
              }catch (UnknownHostException e){
                                     System.out.println("Sock:"+e.getMessage());
              }catch (EOFException e){System.out.println("EOF:"+e.getMessage());
              }catch (IOException e){System.out.println("IO:"+e.getMessage());}
            }finally {if(s!=null) try {s.close();}catch (IOException e)
{System.out.println("close:"+e.getMessage());}}
```

Servidor TCP: em ciclo, aceita ligações

```
import java.net.*;
import java.io.*;
public class TCPServer {
  public static void main (String args[]) {
          try{
                   int serverPort = 7896:
                   ServerSocket listenSocket = new ServerSocket(serverPort);
                   while(true) {
                             Socket clientSocket = listenSocket.accept();
                             Connection c = new Connection(clientSocket);
          } catch(IOException e) {System.out.println("Listen:"+e.getMessage());}
// this figure continues on the next slide
```

Servidor TCP: concorrente, serviço echo

```
class Connection extends Thread {
          DataInputStream in;
          DataOutputStream out;
          Socket clientSocket;
          public Connection (Socket aClientSocket) {
             try {
                     clientSocket = aClientSocket:
                     in = new DataInputStream( clientSocket.getInputStream());
                     out =new DataOutputStream( clientSocket.getOutputStream());
                     this.start();
             } catch(IOException e) {System.out.println("Connection:"+e.getMessage());}
          public void run(){
                                                     // an echo server
            try {
                     String data = in.readUTF():
                     out.writeUTF(data);
             } catch(EOFException e) {System.out.println("EOF:"+e.getMessage());
             } catch(IOException e) {System.out.println("IO:"+e.getMessage());}
             } finally{ try {clientSocket.close();}catch (IOException e){/*close failed*/}}
```

Protocolos de comunicação

- Ad-hoc, feitos à medida
 - Inteiro 1 representa a operação A
 - Inteiro 2 representa a operação B, e segue-se uma string...
- Baseados em normas padronizadas de representação de dados
 - A transformação do pedido para o canal de rede é automática.

٠...

Repr. Externa de Dados e Marshalling

- Processos: <u>estruturas de dados</u>
- Mensagens na Comunicação: <u>sequências de bytes</u>
 - é necessário converter no envio e recepção
 - inteiros: big-endian (byte mais significativo primeiro, como network byte order), little-endian
- para uma estrutura de dados poder usar-se em RPC ou RMI
 - serializável, passível de ser representado de modo flattened e os tipos primitivos num formato acordado
- Representação Externa de Dados
 - formato usado para representação de estruturas e tipos primitivos
- Marshalling
 - tradução das estruturas e tipos primitivos para uma RED adequada para a transmissão
 - unmarshalling: processo inverso para reconstruir os dados à chegada

Repr. Externa de Dados e Marshalling

- Alternativas para RED:
 - CORBA CDR (Common Object Request Broker Architecture CDR)
 - Serialização Java usada em RMI
 - https://docs.oracle.com/javase/tutorial/jndi/objects/serial.html
 - Sun XDR
 - XML
 - JavaScript Object Notation (JSON)
 - http://www.json.org/
 - Protocol Buffers (Google)
 - https://developers.google.com/protocol-buffers/

CORBA CDR (Common Data Representation)

- tipos primitivos (short, long, float... char, boolean, bit) #15 tipos
 - bytes transmitidos de acordo com o emissor (big-endian / little-endian),
 que é também especificada na mensagem

tipos compostos:

Type	Representation
sequence	length (unsigned long) followed by elements in order
string	length (unsigned long) followed by characters in order (can also
	can have wide characters)
array	array elements in order (no length specified because it is fixed)
struct	in the order of declaration of the components
enumerated	unsigned long (the values are specified by the order declared)
union	type tag followed by the selected member

Mensagem CORBA CDR

- não é possível passar uma estrutura com ponteiros
- exemplo com uma Struct:

index in sequence of bytes	◄ 4 bytes →	notes on representation
0–3	5	length of string
4–7	"Smit"	'Smith'
8–11	"h"	"padding"
12–15	6	length of string
16–19	"Lond"	'London'
20-23	"on"	
24–27	1934	unsigned long

Representa uma Struct Person com os valores: {'Smith', 'London', 1934}

Marshalling CORBA

- Operações de Marshalling
 - geradas automaticamente a partir da <u>especificação dos tipos de dados</u> a transmitir na mensagem (argumentos, retorno)
- Tipos descritos com CORBA IDL (interface definition language)
- Assume-se que o emissor e receptor conhecem os tipos de cada elemento da mensagem, por isso o tipo não é passado (apenas o valor)

Java RMI

- objetos e tipos primitivos podem ser transmitidos
 - estes dados são transmitidos como argumento ou resultado de invocação remota de métodos
- formalmente, podem ser transmitidos (argumentos, retorno):
 - tipos primitivos
 - instâncias de classes que implementem a interface java.io.Serializable
- a aplicação que recebe a mensagem pode não conhecer o tipo dos dados
 - a representação serializada inclui informação sobre a classe do objeto (nome, versão/hash)

Serialização em Java

Handle: referência para um objeto incluído na representação serializada

Serialized values

Person	8-byte version number		h0
3	int year	java.lang.String name:	java.lang.String place:
1934	5 Smith	6 London	h1

Explanation

class name, version number number, type and name of instance variables

values of instance variables

h0 e h1 são handles; O valor das Strings é precedido pelo comprimento

Cada objeto é escrito uma só vez, depois pode ser referido pelo seu Handle

Java Reflection

- Java Reflection
 - capacidade de descobrir propriedades de uma classe, como o nome e tipo de variáveis de instância ou métodos.
- Permite criar, obter e descobrir classes até então desconhecidas a partir do nome
- java.lang.reflect

Representação da Referência Remota de um Objeto

- Identificador para um objeto remoto válido no SD
- Cada objeto remoto tem uma única Ref. Remota
 - passada na mensagem do cliente que pede a invocação remota
- É importante garantir que a referência é única universalmente
 - junção de diversos elementos (data de criação...)

32 bits	32 bits	32 bits	32 bits	
Internet address	port number	time	object number	interface of remote object

Serialização em XML

Serialização em XML: esquema XML com tipologia da estrutura

```
<xsd:schema xmlns:xsd = URL of XML schema definitions >
 <xsd:element name= "person" type ="personType" />
      <xsd:complexType name="personType">
         <xsd:sequence>
             <xsd:element name = "name" type="xs:string"/>
             <xsd:element name = "place" type="xs:string"/>
             <xsd:element name = "year" type="xs:positiveInteger"/>
         </xsd:sequence>
      <xsd:attribute name= "id" type = "xs:positiveInteger"/>
 </xsd:complexType>
</xsd:schema>
```

Serialização em JSON

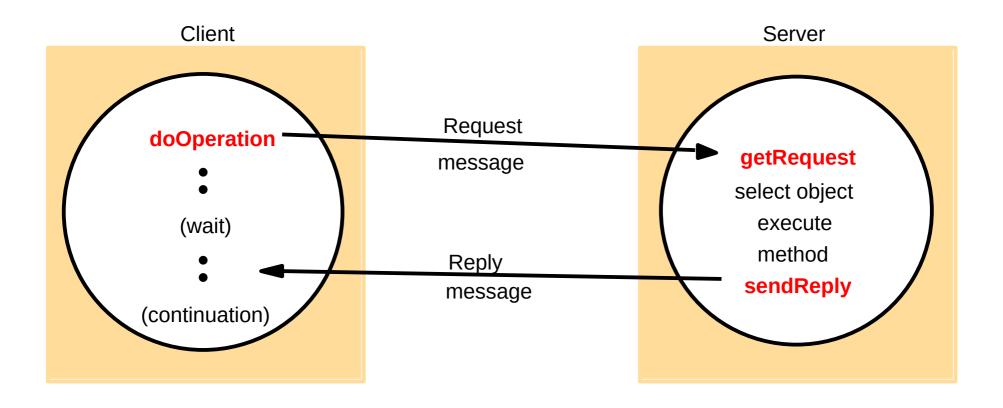
```
{"id": 123456789,
  "name": "Smith",
  "place": "London",
  "year": 1984 }
```

Comunicação Cliente-Servidor

- usualmente baseado em comunicação Request-Reply síncrona
 - pois a resposta do servidor comprova a recepção da mensagem
 - mas também pode ser <u>assíncrona</u> (se o cliente recolhe as respostas mais tarde)
- UDP ou TCP
- UDP evita overhead:
 - ackowledgement aqui s\(\tilde{a}\)o redundantes (j\(\tilde{a}\) temos o reply)
 - estabelecimento da conexão (mais 2 pares de mensagens)
 - controlo de fluxo é desnecessário <u>na maioria dos casos</u> (são passados argumentos e resultados de tamanho reduzido)

Protocolo Request-Reply

assenta em 3 primitivas:



Operações no Protocolo Request-Reply

Primitivas usadas em Request-Reply:

public byte[] doOperation (RemoteObjectRef o, int methodId, byte[] arguments) envia a mensagem com um pedido ao objeto remoto e devolve a resposta. Argumentos: o objeto remoto, o método a invocar e respetivos argumentos.

public byte[] getRequest ();
 através de um porto no servidor, recebe o pedido do cliente

public void sendReply (byte[] reply, InetAddress clientHost, int clientPort); envia a mensagem de resposta para o cliente, através do seu par (endereço,porto)

Modelo de Falhas para Request-Reply

- se implementado sobre UDP: falhas de comunicação
 - falhas de omissão (algumas mensagens podem perder-se)
 - não há garantia de entrega pela mesma ordem do envio
- Falhas relacionadas com os processos (paragem, crash)
- Como tornar o sistema com UDP + fiável (a nível da aplicação):
 - utilizar timeout na operação doOperation, para reenvio de pedido
 - descartar requests duplicados (servidor verifica o identificador)
 - tratar mensagens perdidas caso o servidor já tenha enviado o reply, então o request duplicado é processado para enviar de novo a resposta (se a op. for idempotente, caso contrário deve usar-se uma tabela, designada Histórico – ver adiante)
 - uso de Histórico: tabela com os últimos resultados que permite o reenvio de respostas sem repetir processamento)
 - normalmente precisa apenas da última resposta para cada cliente

RPC

- protocolos usados em RPC:
 - request (R)
 - request-reply (RR)
 - request-reply-acknowledge reply (RRA)
- diferentes comportamentos perante falhas de comunicação
- a sua utilização depende do nº de mensagens necessárias

Name		Messages sent by		
	Client	Server	Client	
R	Request			
RR	Request	Reply		
RRA	Request	Reply	Acknowledge reply	

Request-Reply sobre TCP

- facilita a transmissão de argumentos e resultado de tamanho arbitrário
- mais fiável
- evita a necessidade de filtragem de duplicados e reenvios a nível do protocolo request-reply
- TCP facilita a implementação do protocolo RR
- Exemplo de protocolo RR:
 - HTTP

HTTP: request-reply

Request
method
URL or pathname
HTTP version headers message body

GET //www.dcs.qmw.ac.uk/index.html HTTP/ 1.1

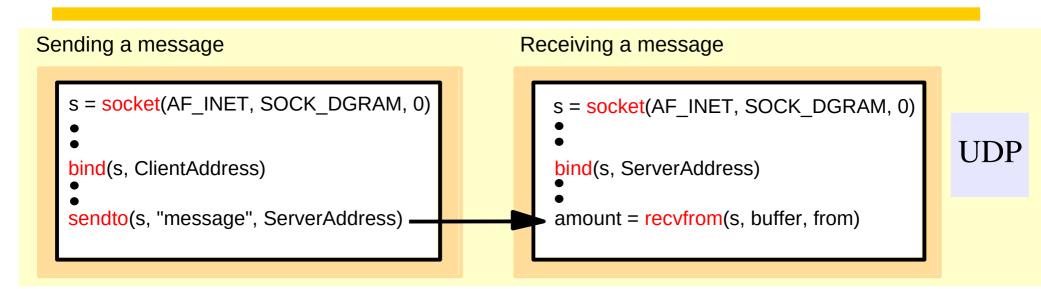
Reply

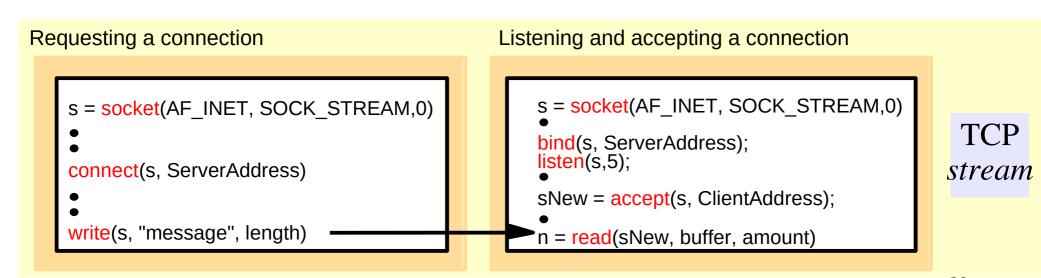
HTTP version	status code	reason	headers	message body
HTTP/1.1	200	OK		resource data

HTTP 1.1: ligações persistentes

•perduram durante várias séries de mensagens request-reply, para evitar o *overhead* do estabelecimento de uma nova ligação

Sockets para Datagramas e Streams





Comunicação em Grupo

- multicast operation: operação que envia uma mensagem de um processo para cada um dos membros de um grupo de processos
- usualmente, a constituição do grupo é transparente para o emissor e não há garantias de entrega ou ordenação
- Multicast fornece uma útil infraestrutura para (construir) SD que incluam:
 - deteção de servidores em spontaneous networking
 - replicação de dados para melhor desempenho
 - tolerância a falhas baseada na replicação dos serviços
 - propagação de notificações de eventos

IP Multicast

- Multicast sobre Internet Protocol (IP)
 - pacotes IP são destinados a endereços (máquinas sem portos (estes dizem respeito à camada de transporte))
- multicast group: definido por um endereço IPv4 classe D
 - ◆ Em particular na gama 224.0.0.0 a 239.255.255.255
 - Endereços geridos pela Internet Assigned Numbers Authority
- é possível enviar datagramas para um grupo sem ser membro
- a nível da programação, o IP Multicast pode usar-se apenas com UDP
 - os dados circulam como datagramas
- ao nível de IP, um computador pertence ao grupo multicast se um ou mais processos tem sockets associados ao grupo

IP Multicast

- Modelo de Falhas no multicast de datagramas
 - falhas de omissão (inerentes ao UDP)
 - alguns membros podem não receber algumas mensagens
 - unreliable multicast: não garante a entrega de uma mensagem para cada membro do grupo
 - ordenação:
 - duas mensagens enviadas por processos diferentes podem não chegar pela ordem de envio
 - os pacotes IP de uma mensagem podem não chegar pela ordem de envio

Java API para IP Multicast: join, troca de datagramas com o grupo

```
import java.net.*;
import java.io.*;
public class MulticastPeer{
         public static void main(String args[]){
          // args give message contents & destination multicast group (e.g. "228.5.6.7")
         MulticastSocket s = null;
          trv {
                   InetAddress group = InetAddress.getByName(args[1]);
                   s = new MulticastSocket(6789);
                   s.joinGroup(group);
                   byte [] m = args[0].getBytes();
                   DatagramPacket messageOut =
                             new DatagramPacket(m, m.length, group, 6789);
                   s.send(messageOut);
```

// this figure continued on the next slide

Java API para IP Multicast: join, troca de datagramas com o grupo

```
// get messages from others in group
        byte[] buffer = new byte[1000];
        for(int i=0; i < 3; i++) 
           DatagramPacket messageIn =
                 new DatagramPacket(buffer, buffer.length);
           s.receive(messageIn);
           System.out.println("Received:" + new String(messageIn.getData()));
        s.leaveGroup(group);
  }catch (SocketException e){System.out.println("Socket: " + e.getMessage());
 }catch (IOException e){System.out.println("IO: " + e.getMessage());}
}finally {if(s != null) s.close();}
```

Comunicação entre Processos - UNIX

- as primitivas para IPC (comunicação entre processos) estão disponíveis em system calls sobre UDP ou TCP
- destino da mensagem: <u>socket address</u> (internet address, port)
- um processo pode criar um socket para comunicar com outro processo, invocando a system call socket
- Comunicação via:
 - datagramas UDP
 - streams TCP

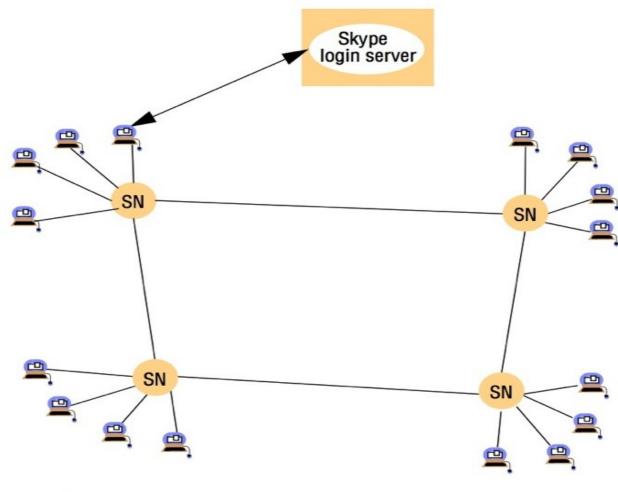
Redes Virtuais

- Network Overlay / Virtual Network
 - Rede virtual formada por um conjunto de nós e ligações lógicas/virtuais entre esses nós
 - Assenta numa rede convencional (como uma rede IP)
 - Esconde aspetos particulares dos segmentos em que assenta... fornece uma plataforma <u>uniforme</u>
 - Oferece serviços adicionais
 - Garantias adicionais de qualidade do serviço
 - Forma de encaminhamento (routing) própria
 - Segurança
 - Outros, vocacionados para determinado serviço específico
 - Possível Desvantagem
 - Eventual perda de desempenho por existir mais uma camada

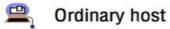
Exemplos: Skype

- Skype: aplicação Peer-to-Peer
 - de VoIP, IM, interfaces para serviço telefónico normal
 - Network overlay system com perto de 400 milhões de utilizadores
- Arquitetura: Peer-to-peer... com
 - Hosts cliente
 - Super nodes: hosts com capacidade suficiente
 - largura de banda, acessibilidade e/ou tempo de ligação ativa
 - endereço público de acessibilidade global
 - capacidade de processamento
- Funcionalidades importantes
 - Pesquisa de utilizadores
 - Envolve a consulta de 8 super nodes, em média
 - Chamadas de voz (TCP para negociar; UDP ou TCP para streaming)

Skype Network Overlay

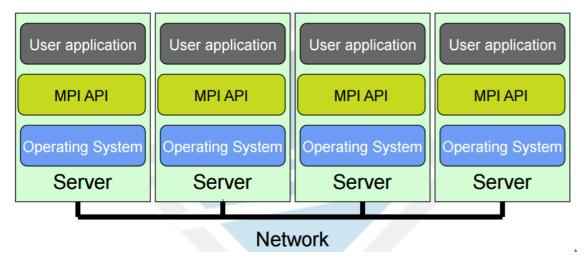


SN Super node



Message Passing Interface (MPI)

 Mecanismo para comunicação entre processos baseado nas primitivas send/receive, usado em programação distribuída, para computação de alto desempenho



A operação send pode ser:

- bloqueante (MPI_Send)
- não bloqueante (MPI ISend)

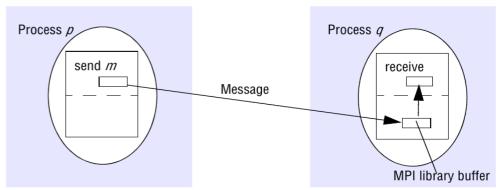


Imagem: